

# Influencia del caudal en la calidad del efluente: Un análisis de las plantas de tratamiento de aguas residuales domésticas en Colombia

Johan Camilo Castro Valencia<sup>1</sup>✉

<sup>1</sup> Grupo de Investigación y Laboratorio de Monitoreo Ambiental G-LIMA, Escuela Ambiental, Facultad De Ingeniería, Universidad De Antioquia, Medellín, Colombia.

✉ [jcamilo.castro@udea.edu.co](mailto:jcamilo.castro@udea.edu.co)

## Abstract

El tratamiento de aguas residuales (AR) es un pilar crítico para la mitigación del impacto ambiental, enfrentando desafíos crecientes debido al crecimiento demográfico y la consecuente generación de efluentes a gran escala. La literatura sugiere que una mayor capacidad operativa en las plantas de tratamiento (PTAR) puede derivar en complejidades de gestión que comprometen la calidad del vertimiento final. El objetivo de este estudio fue determinar la relación entre el caudal de entrada y la calidad del efluente, medido con diversas pruebas fisicoquímicas, en diversas PTARs de Colombia. Utilizando datos del Sistema Único de Información de Servicios Públicos Domiciliarios (SUI), se aplicó un protocolo de preprocesamiento avanzado que incluyó escalamiento robusto, transformación Box-Cox, detección de atípicos e imputación multivariada (KNN) para corregir inconsistencias y sesgos de digitalización. Los resultados mediante análisis de correlación y PCA indican que no existe una dependencia directa entre el volumen de caudal tratado y la calidad del vertimiento. Esto sugiere que la eficacia del saneamiento en el país está vinculada predominantemente a la tecnología de tratamiento empleada y a la gestión operativa, más que a la escala de flujo de la infraestructura.

**Palabras clave:** Caudal, parámetros fisicoquímicos, calidad de agua, preprocesamiento de datos, agua residual doméstica.

## 1. Introduction

El crecimiento demográfico acelerado y la urbanización descontrolada han intensificado la presión sobre los recursos hídricos globales, convirtiendo el tratamiento de aguas residuales (AR) en un desafío técnico y ambiental de primer orden (United Nations, 2017). La gestión de las aguas residuales no solo es una necesidad de salud pública, sino un componente crítico para alcanzar el Objetivo de Desarrollo Sostenible 6: Agua Limpia y Saneamiento. Sin embargo, a medida que los volúmenes de AR aumentan, la infraestructura de saneamiento se enfrenta a complejidades operativas proporcionales a su escala (Metcalf & Eddy, 2014).

En Colombia, el panorama del saneamiento ha experimentado avances significativos en la última década, apalancado por marcos normativos como el Decreto 3930 de 2010 y la Resolución 0631 de 2015. No obstante, persiste una brecha crítica entre la cobertura de alcantarillado y la capacidad efectiva de tratamiento. Según reportes del Sistema Único de Información de Servicios Públicos Domiciliarios (SUI), la diversidad en la escala de las Plantas de Tratamiento de Aguas Residuales (PTAR) en el territorio nacional es vasta, abarcando desde sistemas rurales de bajo flujo hasta infraestructuras metropolitanas que procesan caudales superiores a los 5,000 L/s.

Existe una hipótesis recurrente en la ingeniería ambiental que sugiere que el incremento en la escala de una PTAR (medido a través de su caudal de entrada) conlleva una mayor dificultad en el control de los procesos biológicos y fisicoquímicos, lo cual podría comprometer la calidad del vertimiento final (Sato et al., 2013). Esta relación es particularmente compleja en países en desarrollo, donde las variaciones climáticas, los aportes industriales no controlados y la falta de instrumentación en tiempo real generan datos con altos niveles de ruido, asimetría y valores faltantes (Rodriguez et al., 2020).

Desde el punto de vista del análisis de datos, los registros ambientales nacionales suelen presentar desafíos estadísticos que invalidan los métodos de inferencia convencionales. La presencia de sesgos extremos (asimetría) y la heterocedasticidad en variables como la Demanda Química de Oxígeno (DQO) y el Caudal exigen la aplicación de protocolos de preprocesamiento avanzado, tales como transformaciones y algoritmos de imputación multivariada, para garantizar que las conclusiones no sean producto de artefactos estadísticos o errores de digitalización (Box & Cox, 1964; Kuhn & Johnson, 2013).

El objetivo de este proyecto fue determinar la correlación existente entre el caudal de entrada y la calidad del agua efluente en las PTAR de Colombia, utilizando un enfoque de ciencia de datos. A través del análisis multivariado y técnicas de reducción de dimensionalidad (PCA), se busca identificar si la escala operativa es el factor determinante en la eficiencia del vertimiento o si, por el contrario, la calidad responde a variables de gestión y configuración tecnológica independientes del flujo de trabajo.

## **2. Metodología**

La metodología se fundamentó en un enfoque de ciencia de datos aplicado a datos ambientales, la cual se estructuró en cuatro fases: la adquisición de los datos, la limpieza, el preprocesamiento avanzado y el análisis multivariado.

### **2.1. Origen y características del conjunto de datos**

Los datos usados se extrajeron del sistema único de información de servicios públicos domiciliarios (SUI) de Colombia, en él se encuentra información administrativa, variables de operación y la calidad de agua vertida de diferentes plantas de tratamiento a lo largo del país. Las variables críticas que se seleccionaron para hablar de la calidad del agua vertida fueron variables físicas como la Temperatura [°C] y variables químicas como el pH, la demanda química de oxígeno (DQO) [kg/d], la demanda biológica de oxígeno (DBO) [kg/d] y los sólidos totales [mg/L]; estas variables se relacionaron con otra variable física que no habla de la calidad, si no de la cantidad de agua tratada en la planta y es el caudal medio anual de entrada [L/s]. El análisis inicial fue netamente exploratorio, donde se encontró que el dataset presentaba alta asimetría y una presencia significativa de datos faltantes, lo que hizo necesaria una limpieza y preprocesamiento avanzado de los mismos para el análisis final.

### **2.2. Limpieza de datos**

Dada la naturaleza diversa de los reportes, donde cada uno de ellos proviene de diferentes regiones, se tuvieron que seguir una serie de pasos para la limpieza de los mismos; primero se llevó a cabo la eliminación de espacios en blanco al inicio y al final de los nombres de las columnas utilizando la función `strip()`. Se identificó que algunas variables fisicoquímicas críticas tenían registros con un valor de “0”, situación que es físicamente imposible para la calidad del agua, entonces las columnas se convirtieron a tipo numérico reemplazando además los ceros por valores nulos (NaN) para que no se afectaran los cálculos estadísticos. Adicionalmente se eliminaron los registros que no reportaban más del 25% de los datos debido a que la imputación de plantas de tratamiento con tantos datos vacíos termina siendo riesgosa debido a que cada planta tiene particularidades únicas que, si bien se pueden extrapolar en algunos casos, con la cantidad de datos faltantes que se presentaban era como crear una nueva observación, además, se evaluó la presencia de duplicados para eliminar aquellos registros exactamente iguales.

### **2.3. Preprocesamiento avanzado**

Una vez evaluado el comportamiento de las variables, se pusieron a prueba varios métodos de escalado para los datos y se identificó que `RobustScaler` fue el mejor para escalar las variables numéricas, por lo que se utilizó para tratar los datos y mitigar así la influencia de valores extremos. También se compararon diferentes métodos matemáticos de transformación (logarítmica, logarítmica reflejada, raíz cuadrada, raíz cúbica y `box-cox`) con el fin de estabilizar la varianza y normalizar la distribución de cada variable. Una vez transformadas las variables, se procedió con la identificación de datos atípicos y el porcentaje de estos en la

variable, donde no se eliminaron atípicos debido a su bajo porcentaje y que una vez analizados individualmente se determinó que podrían ser casos excepcionales (como plantas donde además de aguas residuales domiciliarias también entren aguas industriales, generando así esas características atípicas respecto a los demás datos) Finalmente, se hizo un tratamiento de imputación, donde se utilizó el método *K-nearest neighbors* (KNN) debido a la naturaleza aleatoria de los mismos y así llenar los espacios vacíos restantes de la limpieza inicial.

## **2.4. Análisis exploratorio y multivariado**

El análisis exploratorio se hizo en dos etapas, la primera donde se calcularon las medidas estadísticas descriptivas que permitieron observar el comportamiento de las variables (media, mediana, valor mínimo, valor máximo, rango, varianza, desviación estándar, coeficiente de variación, asimetría y curtosis). Esto se visualizó mediante histogramas de densidad donde se incluyeron líneas de referencia para valores como la media, la mediana y desviaciones. Adicionalmente, se realizó un análisis geográfico exploratorio, donde se contabilizó y graficó la cantidad de PTARs registradas por departamento para identificar un primer acercamiento a la distribución de plantas en el país. Finalmente, se realizó una matriz de dispersión antes y después de todo el proceso de limpieza de datos, con el fin de identificar los cambios antes del preprocesamiento y también identificar la relación entre las variables para ver si el caudal se podría relacionar con las demás o con algunas de ellas; esto derivó en un análisis de componentes principales para reducir la dimensionalidad de la base de datos y agrupar las diferentes variables en diferentes componentes.

## **3. Resultados y discusión**

### **3.1. Tratamiento de datos y calidad de la muestra**

El trabajo comenzó con una muestra de 1152 observaciones, durante las actividades de preprocesamiento se identificó que el 3,9% de los registros presentaban ausencia de datos superiores al 25% por lo que fueron descartados para preservar la integridad estadística y no generar “nuevas” PTARs. Algo relevante que se encontró en la fase de limpieza y detección de datos atípicos fue la identificación de posibles errores en la integridad del reporte, donde se identificaron reportes con valores de parámetros fisicoquímicos que no son los más comunes para las plantas de tratamiento de aguas residuales domésticas, pero que sí pueden serlo para plantas de tratamiento de aguas residuales industriales. Esta situación ya supone un desafío muy grande en la estandarización de reportes de información sectorial, donde la posible falta de instrumentalización obliga a los operadores regionales a replicar valores estimados.

Además, la diferencia en los registros evidencia las dificultades relacionadas con el manejo de bases de datos ambientales a escala nacional, donde las diferencias en capacidad operativa, infraestructura analítica y frecuencia de monitoreo entre regiones pueden influir directamente en la calidad y consistencia de la información reportada. A pesar de estas limitaciones, el proceso de depuración permitió conservar una muestra representativa del comportamiento de las PTARs. Esto resalta la necesidad de fortalecer los protocolos de monitoreo y validación de datos ambientales, así como de implementar sistemas de reporte más estandarizados que

permitan mejorar la trazabilidad y confiabilidad de la información utilizada para la gestión del recurso hídrico y la formulación de políticas públicas.

### 3.2. Análisis descriptivo y efecto de la transformación

El análisis univariado para cada variable reveló distribuciones con una asimetría positiva extrema (valores muy altos). La variable “Caudal medio anual a la entrada (L/s)” presentaba un coeficiente de asimetría de 33,23 y una curtosis de 1116,67 indicando una concentración masiva de plantas pequeñas y unas pocas con gran capacidad que extienden esa “cola” hacia la derecha. Para mitigar este sesgo entre plantas de pequeña y gran capacidad se aplicó una transformación Box-Cox que, contrario a lo que generalmente se hace con los datos biológicos resultó ser la más efectiva para reducir la asimetría y la curtosis como se muestra en la Tabla 1.

Tabla 1. Cambio en la asimetría y la curtosis luego de la transformación con Box-cox.

| Variable               | Asimetría<br>(original) | Curtosis<br>(original) | Asimetría<br>(Box-cox) | Curtosis<br>(Box-cox) |
|------------------------|-------------------------|------------------------|------------------------|-----------------------|
| Caudal (L/s)           | 33,23                   | 1116,67                | 0,068                  | -0.053                |
| pH                     | 3,06                    | 97,32                  | 0,297                  | 19,84                 |
| DQO (kg/d)             | 1,21                    | 2,88                   | 0,018                  | 0,349                 |
| DBO (kg/d)             | 2,26                    | 7,91                   | 0,034                  | 0,719                 |
| Temperatura (°C)       | -1.21                   | 10,24                  | 0,739                  | 18,99                 |
| Sólidos totales (mg/L) | 2,41                    | 5,45                   | 0,061                  | -0,013                |

La disminución simultánea de la asimetría y la curtosis después de la transformación Box-Cox indica una reducción significativa de la influencia de valores extremos y una aproximación más cercana a distribuciones normales (Box & Cox, 1964). Esto resulta especialmente importante para técnicas multivariadas como el análisis de componentes principales (PCA), ya que evita que unas pocas observaciones de gran magnitud dominen la estructura estadística del sistema y distorsionen las relaciones entre variables (Jolliffe, 2002; Kuhn & Johnson, 2013).

Los resultados muestran que las variables originales no seguían una distribución normal, condición frecuente en sistemas ambientales donde predominan procesos altamente heterogéneos y dependientes de factores regionales, demográficos e industriales (Limpert et al., 2001). La presencia de valores extremos elevados refleja la desigualdad en la capacidad operativa de las PTAR colombianas, donde un reducido número de plantas metropolitanas concentra grandes volúmenes de tratamiento mientras la mayoría corresponde a sistemas de pequeña escala distribuidos en zonas rurales o intermedias (Ministerio de Vivienda, Ciudad y Territorio, 2020; Rodríguez et al., 2020). Esto sugiere que los sistemas de tratamiento en

Colombia presentan una alta diversidad que debe ser considerada en futuros procesos de planificación y regulación ambiental.

### **3.3. Detección crítica de atípicos y su interpretación ambiental**

Tras normalizar los datos se usó el método de Tukey (IQR) para determinar la presencia de datos atípicos y aislarlos para analizar esas observaciones por separado (Tukey, 1977). La detección de valores atípicos en sistemas ambientales no necesariamente implica la presencia de errores de medición, ya que muchos de estos registros pueden representar condiciones operativas reales asociadas a actividades industriales, variaciones climáticas o diferencias tecnológicas entre plantas de tratamiento (Hodge & Austin, 2004). En este sentido, los datos extremos deben interpretarse desde una perspectiva ambiental y no únicamente estadística, especialmente en sistemas complejos y heterogéneos como las PTARs (Rodríguez et al., 2020).

#### **3.3.1. Caudal**

Fue notable que después del escalado con RobustScaler y la transformación con Box-cox lo que parecían datos atípicos no persisten, esto demuestra que la varianza del volumen de agua en Colombia es continua y que las grandes plantas no son errores estadísticos, sino que son el extremo superior de la distribución normalizada, donde la mayoría de las plantas son las de pequeña escala (Box & Cox, 1964). El hecho de que los valores extremos desaparecieran después de la transformación sugiere que la distribución del caudal posee una naturaleza de escalado. Esto evidencia que la diferencia entre pequeñas y grandes PTARs responde a la operatividad del sistema y no a errores (Kuhn & Johnson, 2013). Además, confirma que el preprocesamiento permitió separar adecuadamente la variabilidad estructural del sistema de los verdaderos valores atípicos.

#### **3.3.2. pH**

Se identificaron en total 36 valores atípicos, donde sus valores se encuentran entre 5.67 y 6.14 en departamentos como Valle Del Cauca y Cundinamarca. Según Metcalf & Eddy (2014), el rango óptimo para el tratamiento biológico de agua oscila entre 6,5 y 8,5. La presencia de estos valores atípicos que representan valores ácidos sugiere descargas industriales no neutralizadas que, desde el punto de vista microbiológico, valores por debajo del rango óptimo pueden afectar significativamente la actividad metabólica de los microorganismos responsables de la degradación biológica de la materia orgánica (Madigan et al., 2015). Esto podría traducirse en pérdidas de eficiencia en la remoción de contaminantes, acumulación de compuestos intermedios y posible inestabilidad operacional.

#### **3.3.3. Temperatura**

Respecto a la temperatura se observaron 8 registros atípicos, donde algunos corresponden a temperaturas por encima de los 45°C, con un valor alto de 101°C; estos valores pueden indicar que se vierten y reciben aguas industriales sin estabilizar y pueden representar riesgos ambientales graves en el sitio exacto donde son vertidas o representar riesgos para los consorcios microbianos de las PTARs, estos valores también muestran la necesidad de

fortalecer los mecanismos de validación y control de calidad de la información reportada en plataformas nacionales, debido a que también puede ser un error de digitación o fallos en los instrumentos de medición (Ministerio de Ambiente y Desarrollo Sostenible, 2015). Por otro lado, hay registros de temperatura con valores por debajo de los 15°C, esto puede deberse a la ubicación geográfica de las plantas, sin embargo, estos valores pueden presentar riesgos para las comunidades microbianas en las plantas, pero no al medio ambiente (Von Sperling, 2007).

### **3.3.4. Carga orgánica**

Cuando se habla de carga orgánica se hace referencia a la cantidad de materia orgánica contaminante presente en las aguas residuales y de manera general se puede entender como el alimento que los microorganismos deben consumir para dejar el agua limpia, de los parámetros fisicoquímicos evaluados, la de DQO y la DBO son aquellos que dan cuenta de la carga orgánica, para estas variables se encontraron 14 y 27 valores atípicos, respectivamente. Los atípicos presentes corresponden a valores altos que se relacionan con grandes centros urbanos donde la presión antrópica genera estas condiciones altas de carga orgánicas (Henze et al., 2008). La concentración de estos atípicos en grandes centros urbanos podría indicar también que, aunque las PTARs de estas regiones poseen mayores capacidades hidráulicas, continúan enfrentando retos importantes relacionados con sobrecargas orgánicas y expansión acelerada de la demanda sanitaria.

### **3.3.5. Sólidos totales**

Respecto a estos, los valores atípicos corresponden a valores muy bajos, donde el valor de sólidos indica que los procesos de tratamiento de agua son muy buenos removiendo la carga contaminante o el agua que llega a las plantas tiene muy poco material sedimentable, sin embargo, esto debe compararse con los datos de la carga orgánica debido a que la calidad del agua no se puede determinar solo mediante un parámetro fisicoquímico (Tchobanoglous et al., 2003).

En conjunto, el análisis de datos atípicos permitió evidenciar que gran parte de la variabilidad observada en las PTAR colombianas responde a diferencias reales en condiciones operativas, ubicación geográfica y composición de los afluentes. Por ello, la conservación de estos registros resultó metodológicamente pertinente para mantener la representatividad del sistema nacional de saneamiento. No obstante, algunos valores extremos también sugieren posibles inconsistencias en los procesos de reporte y monitoreo, resaltando la necesidad de fortalecer la estandarización y trazabilidad de los datos ambientales en Colombia.

## **3.4. Análisis de correlación y estructura multivariada**

La matriz de correlación presentada en la Figura 1 evidencia que no existe una dependencia fuerte entre el caudal y la calidad del agua después de los tratamientos expresada en las demás variables. Este fenómeno indica que el sistema de saneamiento de las diferentes regiones de Colombia tiene buena capacidad de dilución, es decir, que el incremento de en el volumen de agua residual no conlleva un aumento proporcional en la carga contaminante absoluta y que las plantas de tratamiento responden bien a las necesidades de cada región en específico

(Rodriguez et al., 2020). Sin embargo, se encontraron correlaciones interesantes y otras esperadas; la DQO y la DBO tuvieron una correlación alta, situación esperada porque ambas dan cuenta de la carga orgánica del agua residual y a su vez tienen una correlación un poco más baja con los sólidos totales que dentro de su medida contiene estas variables, adicional a la materia inorgánica (Metcalf & Eddy, 2014; Rice et al., 2017). Otra correlación interesante es la observada entre la temperatura y el pH, la cual podría estar asociada a la influencia conjunta de factores biológicos, climáticos e industriales sobre las características del agua residual. En sistemas biológicos de tratamiento, la temperatura afecta directamente la actividad metabólica de los microorganismos y, en consecuencia, los procesos bioquímicos que modifican el equilibrio ácido-base del sistema (Von Sperling, 2007). Asimismo, regiones con temperaturas más elevadas suelen presentar mayores velocidades de degradación de materia orgánica, favoreciendo cambios en la alcalinidad y en la dinámica del pH (Madigan et al., 2015).




Figura 1. Matriz de correlación entre variables.

La ausencia de correlaciones fuertes entre el caudal y las variables fisicoquímicas sugiere que el desempeño de las PTAR no depende exclusivamente de la magnitud hidráulica del sistema, sino de factores asociados a la eficiencia del tratamiento, la composición del afluente y las condiciones operativas específicas de cada región (Sato et al., 2013). Esto evidencia que plantas de diferentes tamaños pueden alcanzar comportamientos similares en términos de calidad del efluente tratado (Mara, 2004). Además, el comportamiento observado confirma que el preprocesamiento aplicado logró reducir la influencia artificial de los valores extremos,



permitiendo que las relaciones entre variables reflejaran tendencias reales del sistema y no únicamente diferencias de escala entre observaciones.

Adicionalmente, se redujo la dimensionalidad del sistema para evaluar cómo se podrían agrupar las diferentes variables para describir las plantas colombianas de acuerdo a ellas. Los resultados se presentan en la Figura 2, donde se observa cuál o cuales de las variables son las que más influencia tienen en el componente principal y en la Figura 3 se presentan los autovalores de cada uno de los componentes, donde valores por encima de uno nos hacen considerarlos y se concluye que el sistema se podría resumir en tres componentes principales (Kaiser, 1960). El análisis de componentes principales permitió identificar que gran parte de la variabilidad del sistema puede explicarse mediante un número reducido de dimensiones latentes, simplificando la complejidad estadística de las PTAR colombianas sin perder información relevante.




Figura 2. Autovectores de los componentes principales del PCA.

El primer componente principal estuvo dominado principalmente por el caudal, representando la dimensión hidráulica y operacional de las PTAR. Este componente diferencia las plantas de gran capacidad ubicadas en áreas metropolitanas de los sistemas de menor escala presentes en municipios intermedios y zonas rurales. El segundo componente agrupó variables asociadas a la carga orgánica y sólidos, reflejando la presión contaminante que recibe cada sistema. Esta dimensión puede interpretarse como un indicador de la intensidad antropogénica y del tipo de actividad económica predominante en las regiones analizadas. El tercer componente relacionó principalmente el pH y la temperatura, variables estrechamente vinculadas con las condiciones ambientales y la estabilidad de los procesos biológicos de tratamiento. Esto sugiere que las diferencias climáticas y las características fisicoquímicas regionales constituyen una dimensión independiente dentro del comportamiento global de las PTAR en Colombia. Lo anterior implica que la evaluación del desempeño de una PTAR no debería realizarse únicamente a

partir de un solo parámetro, sino mediante enfoques integrales que consideren simultáneamente diferentes dimensiones operativas y ambientales.




Figura 3. Autovalores de los componentes principales del PCA.

### 3.5. Variabilidad regional

La distribución geográfica de las PTARs evidencia que las condiciones climáticas, de altitud y socioeconómicas de cada región influyen directamente en el comportamiento operativo y la calidad del afluente tratado (Von Sperling, 2007). En Colombia, las plantas ubicadas en zonas de alta montaña enfrentan temperaturas más bajas que reducen la velocidad de degradación biológica y obligan a operar con mayores tiempos de retención, mientras que las PTARs localizadas en regiones cálidas presentan cinéticas microbianas más rápidas y condiciones más favorables para los procesos biológicos, aunque también mayores riesgos asociados a septicidad, generación de olores y emisiones gaseosas no controladas (Metcalf & Eddy, 2014; Mara, 2004). Asimismo, la concentración de valores atípicos en departamentos con mayor crecimiento económico e industrial sugiere que la composición del agua residual está estrechamente relacionada con la vocación productiva regional, donde actividades industriales y agroindustriales pueden modificar significativamente las características fisicoquímicas del afluente (Henze et al., 2008; Rodriguez et al., 2020). Estas diferencias evidencian que el sistema de saneamiento colombiano posee una alta heterogeneidad funcional y territorial, por lo que el diseño, operación y regulación de las PTARs no deberían abordarse mediante criterios homogéneos, sino a través de estrategias y políticas de vertimiento diferenciadas que consideren las particularidades ambientales, climáticas y económicas de cada región del país (Ministerio de Ambiente y Desarrollo Sostenible, 2015; United Nations, 2017).

## 4. Conclusiones

El análisis de datos de las plantas de tratamiento de aguas residuales en Colombia permitió evidenciar la importancia de aplicar metodologías robustas de ciencia de datos para el tratamiento de información ambiental compleja, heterogénea y con altos niveles de variabilidad. La combinación de técnicas de limpieza, transformación, escalado e imputación permitió mejorar significativamente la calidad estadística del conjunto de datos y facilitar la identificación de patrones relevantes en el comportamiento de las variables fisicoquímicas evaluadas.

Los resultados mostraron que las variables originales presentaban distribuciones altamente asimétricas, especialmente el caudal, reflejando la coexistencia de una gran cantidad de sistemas pequeños y un número reducido de PTARs de gran capacidad. La transformación y el uso de escalado permitieron comparar plantas de diferentes escalas dentro de un mismo marco analítico. Adicionalmente, la detección e interpretación de datos atípicos reveló información ambiental relevante más allá de simples anomalías estadísticas. En varios casos, los valores extremos podrían estar asociados a descargas industriales, diferencias regionales o condiciones operativas particulares de las PTARs, lo que resalta la necesidad de considerar el contexto territorial y económico en la evaluación de la calidad del agua residual. Asimismo, la permanencia de estos registros en el análisis permitió conservar la diversidad inherente del sistema de saneamiento.

El análisis multivariado mostró que el caudal no presenta una relación fuerte con la calidad final del agua tratada, lo que sugiere que muchas PTARs responden adecuadamente a las demandas hidráulicas de sus regiones. Además, el análisis de componentes principales permitió resumir el comportamiento del sistema en tres dimensiones fundamentales relacionadas con el tamaño de la planta, la carga orgánica y las condiciones de operación del tratamiento, evidenciando que las PTARs en Colombia están influenciadas tanto por factores operativos como por condiciones geográficas y económicas.

Finalmente, este trabajo evidencia el potencial de las herramientas de análisis de datos para fortalecer la gestión ambiental y la toma de decisiones en el sector de saneamiento. No obstante, también pone en evidencia desafíos importantes relacionados con la calidad y estandarización de los reportes oficiales, lo que resalta la necesidad de mejorar los procesos de monitoreo, instrumentación y consolidación de información ambiental en el país.

## Data and Code Availability

Los datos utilizados para este proyecto fueron extraídos del sistema único de información de servicios públicos domiciliarios, la cual es una base de datos abierta. En el siguiente link se puede acceder a la base de datos.

url: [http://reportes.sui.gov.co/fabricaReportes/frameSet.jsp?idreporte=alc\\_tec\\_005](http://reportes.sui.gov.co/fabricaReportes/frameSet.jsp?idreporte=alc_tec_005)

## Supplementary Materials

El material complementario consiste en un notebook en Google colab donde se registró todo el tratamiento de datos, los códigos usados y donde también se encuentran las gráficas mostradas en este proyecto. En el siguiente link se puede ingresar al material ubicado en un espacio de trabajo de Github.

url: [https://github.com/jcamilocastro/analisis\\_aguas/tree/main](https://github.com/jcamilocastro/analisis_aguas/tree/main)

## Referencias

1. Box, G. E., & Cox, D. R. (1964). An Analysis of Transformations. *Journal of the Royal Statistical Society: Series B (Methodological)*, 26(2), 211–243.
2. Kuhn, M., & Johnson, K. (2013). *Applied Predictive Modeling*. Springer.
3. Metcalf & Eddy. (2014). *Wastewater Engineering: Treatment and Resource Recovery* (5<sup>th</sup> ed.). McGraw-Hill Education.
4. Ministerio de Ambiente y Desarrollo Sostenible. (2015). *Resolución 0631 de 2015: Parámetros y valores límites máximos permisibles en vertimientos puntuales a cuerpos de agua superficiales y a los sistemas de alcantarillado público*. Bogotá, D.C.
5. Rodriguez, S., et al. (2020). *Challenges and opportunities in wastewater data management in developing countries*. *Water Science and Technology*, 82(12), 2611–2625.
6. Sato, T., et al. (2013). *Global, regional, and country level need for sustainable municipal wastewater treatment*. *Wastewater Management*, 37, 1–9.
7. United Nations. (2017). *The UN World Water Development Report 2017: Wastewater, The Untapped Resource*. UNESCO.
8. Jolliffe, I. T. (2002). *Principal Component Analysis*. Springer Series in Statistics.
9. Limpert, E., Stahel, W. A., & Abbt, M. (2001). *Log-normal Distributions across the Sciences: Keys and Clues*. *BioScience*, 51(5), 341–352.
10. Ministerio de Vivienda, Ciudad y Territorio. (2020). *Inventario Nacional de Plantas de Tratamiento de Aguas Residuales Municipales en Colombia*. Bogotá, D.C.
11. Henze, M., van Loosdrecht, M. C., Ekama, G. A., & Brdjanovic, D. (2008). *Biological Wastewater Treatment: Principles, Modelling and Design*. IWA publishing.

12. Hodge, V. J., & Austin, J. (2004). *A survey of outlier detection methodologies*. Artificial Intelligence Review.
13. Madigan, M. T., Martinko, J. M., Bender, K. S., & Buckley, D. H. (2015). *Brock Biology of Microorganisms*. Pearson.
14. Tchobanoglous, G., Burton, F. L., & Stensel, H. D. (2003). *Wastewater Engineering: Treatment and Reuse*. Metcalf & Eddy, Inc.
15. Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
16. Von Sperling, M. (2007). *Basic Principles of Wastewater Treatment*. IWA Publishing.
17. Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2018). *Multivariate Data Analysis*. Cengage Learning.
18. Kaiser, H. F. (1960). *The application of electronic computers to factor analysis*. Educational and Psychological Measurement, 20(1), 141-151.
19. Mara, D. (2004). *Domestic Wastewater Treatment in Developing Countries*. Earthscan.
20. Rice, E. W., Baird, R. B., & Eaton, A. D. (2017). *Standard Methods for the Examination of Water and Wastewater*. AWWA, APHA, WEF.